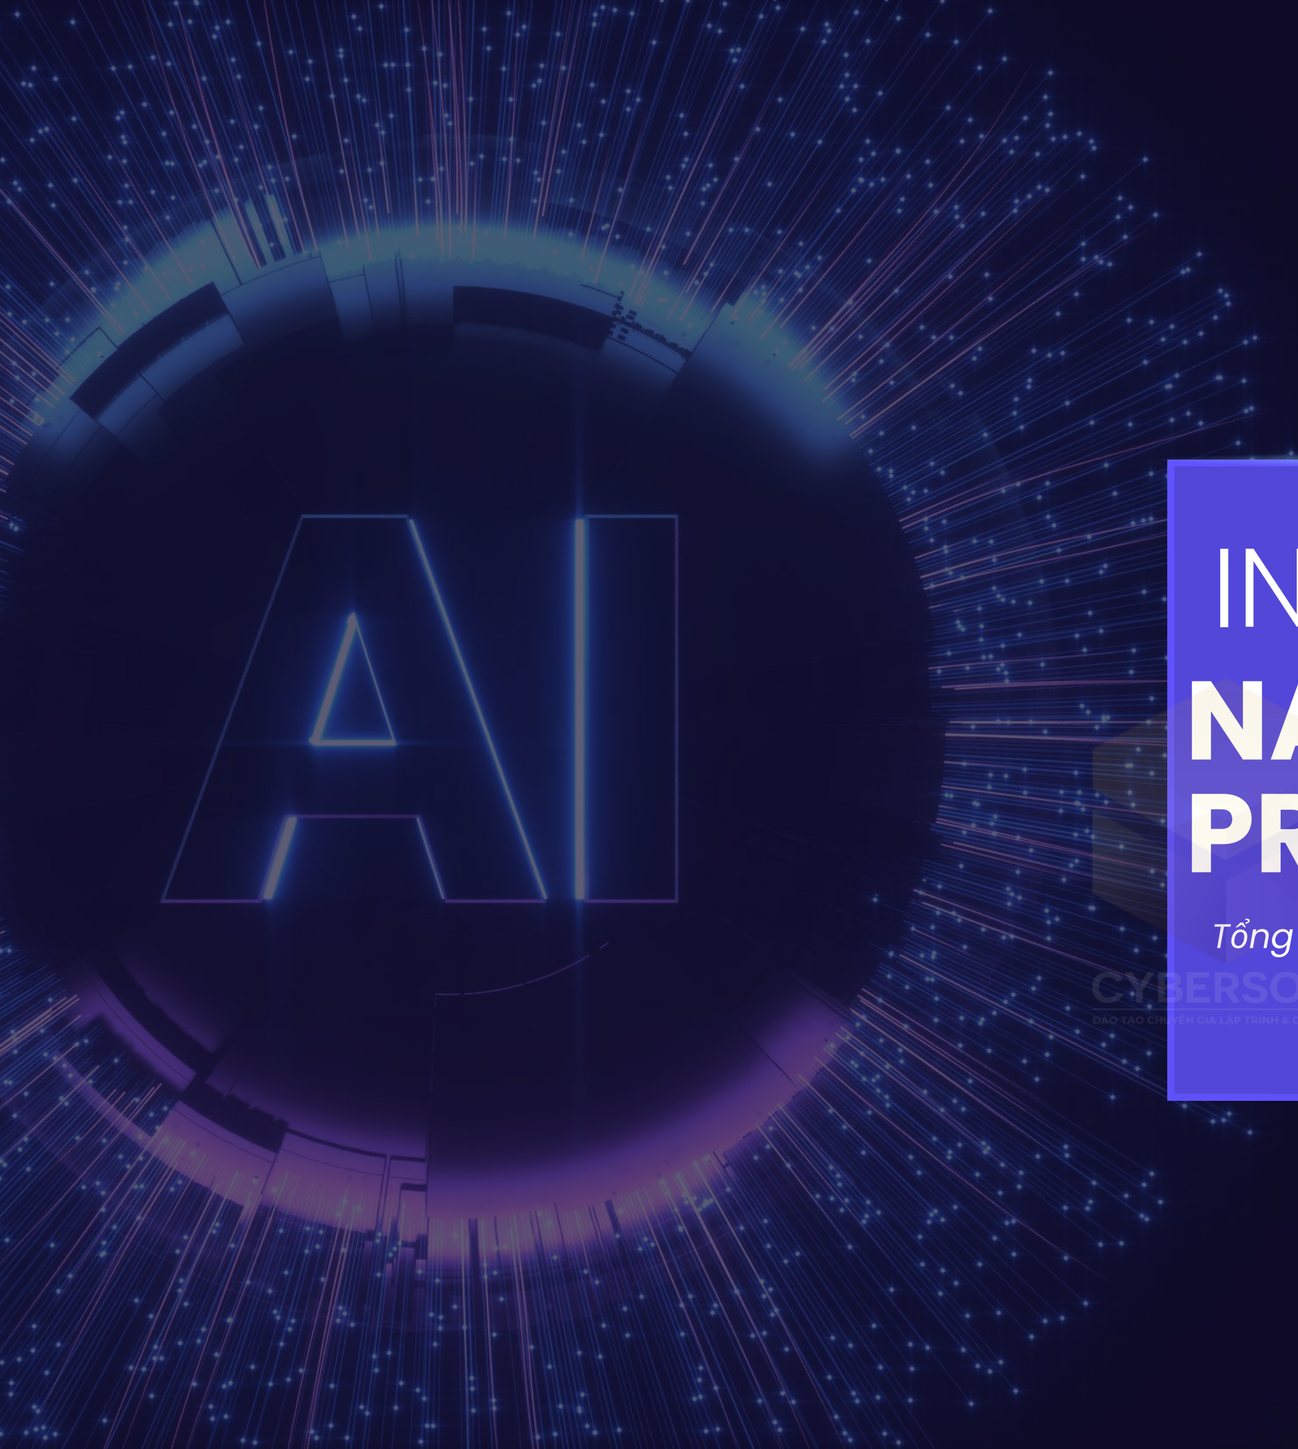


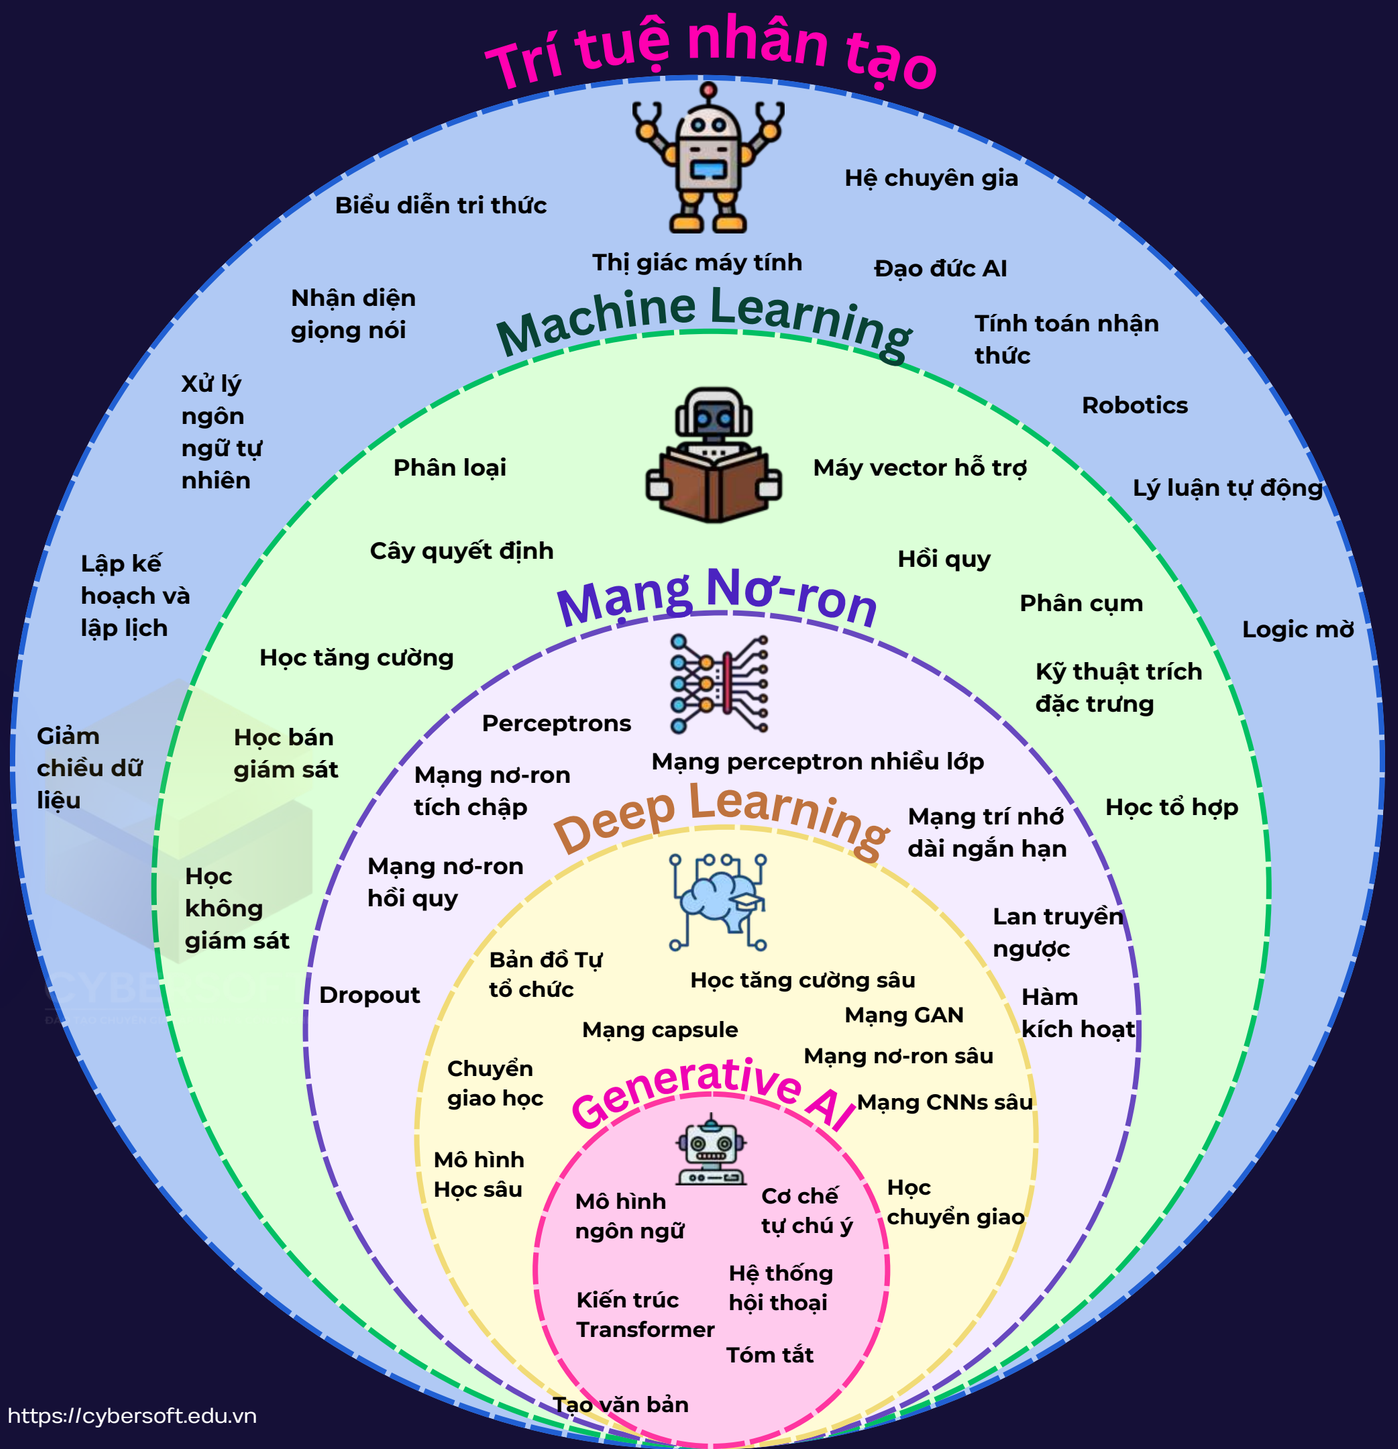
CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

INTRODUCTION
NATURAL LANGUAGE PROCESSING

Tổng quan và các phương pháp xử lý văn bản tiên tiến với NLP

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

AI UNIVERSE


Trí tuệ nhân tạo
Hệ chuyên gia
Biểu diễn tri thức
Thị giác máy tính
Đạo đức AI
Nhận diện giọng nói
Machine Learning
Tính toán nhận thức
Xử lý ngôn ngữ tự nhiên
Robotics
Phân loại
Máy vector hỗ trợ
Lý luận tự động
Cây quyết định
Hồi quy
Lập kế hoạch và lập lịch
Mạng Nơ-ron
Phân cụm
Logic mờ
Học tăng cường
Kỹ thuật trích đặc trưng
Perceptrons
Giảm chiều dữ liệu
Học bán giám sát
Mạng perceptron nhiều lớp
Mạng nơ-ron tích chập
Deep Learning
Học tổ hợp
Mạng trí nhớ dài ngắn hạn
Mạng nơ-ron hồi quy
Học không giám sát
Lan truyền ngược
Bản đồ Tự tổ chức
Học tăng cường sâu
Dropout
Hàm kích hoạt
Mạng GAN
Mạng capsule
Mạng nơ-ron sâu
Chuyển giao học
Generative AI
Mạng CNNs sâu
Mô hình Học sâu
Mô hình ngôn ngữ
Cơ chế tự chú ý
Học chuyển giao
Hệ thống hội thoại
Kiến trúc Transformer
Tóm tắt
Tạo văn bản

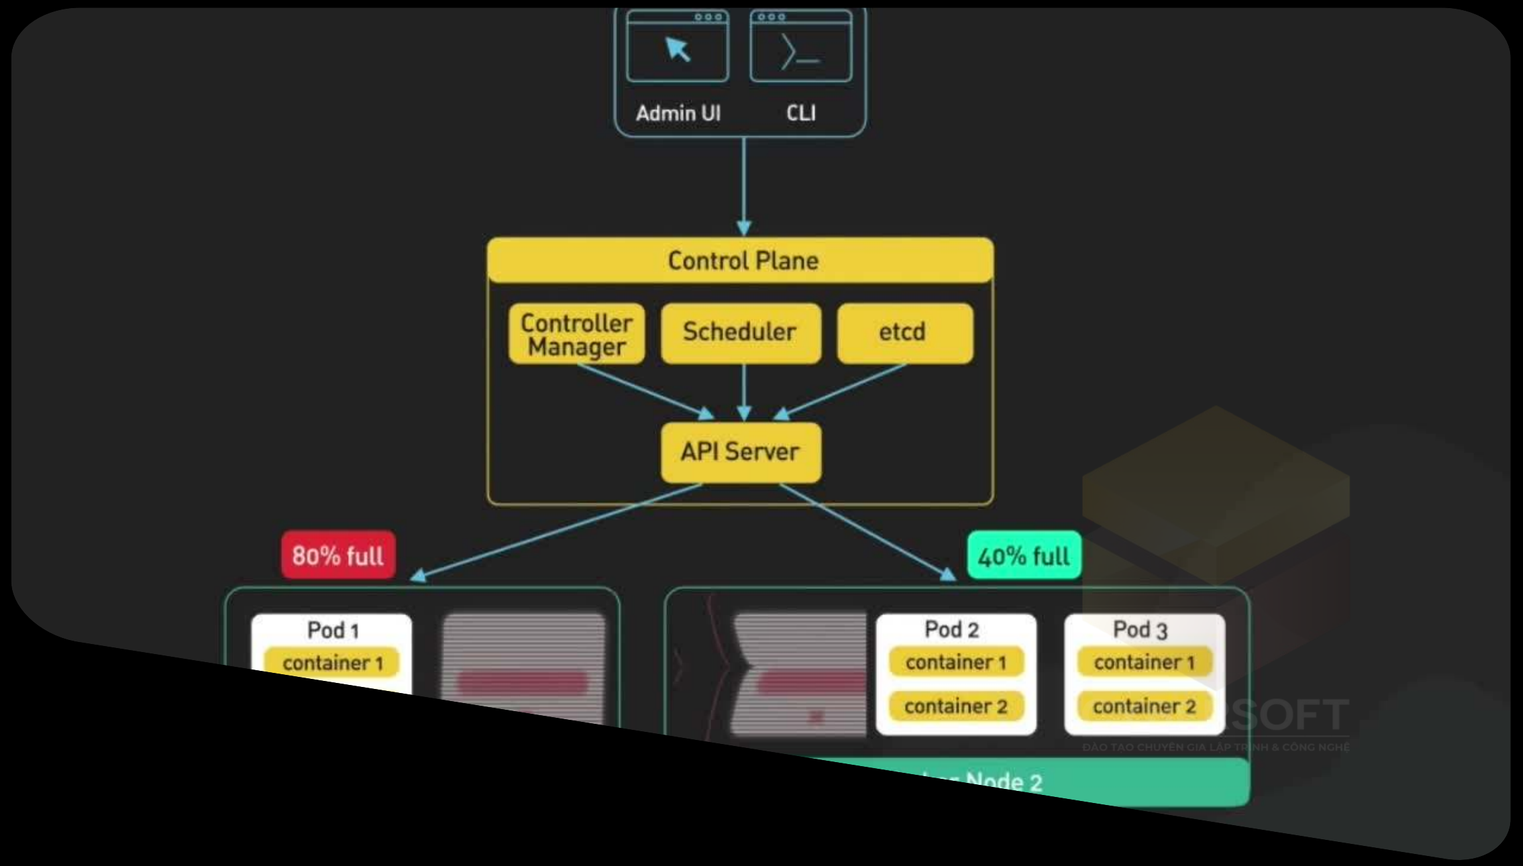


Mục tiêu & kết quả

- Tìm hiểu về Natural Language Processing (NLP) – là một lĩnh vực con của trí tuệ nhân tạo (AI), nơi máy tính tập trung vào việc hiểu, diễn giải và tạo ra ngôn ngữ tự nhiên như của con người
- Buổi học này được thiết kế để cung cấp cái nhìn tổng quan về khái niệm NLP, các ứng dụng thực tiễn và đặc biệt tập trung vào các kỹ thuật tiền xử lý văn bản cơ bản. Dưới đây là các kiến thức cần nắm trong buổi học:

- **Làm quen với NLP**
- **NLP và ML - DL**
- **Ứng dụng thực tế**
- **Spacy và NLTK**
- **Tokenization, Stemming, Lemmatization, Stop-words, và Vocabulary-matching**
- **Thực hành dự án phân loại email Spam**

Chắc hẳn các bạn đã làm quen với



01 Tiền xử lý dữ liệu dạng bảng và ảnh

02 Huấn luyện mô hình Machine Learning

03 Phát triển và finetune các mô hình Deep Learning

04 Làm việc với dữ liệu lớn (Big Data)

05 Đánh giá mô hình học máy và học sâu

06 .....nhiều thứ nữa

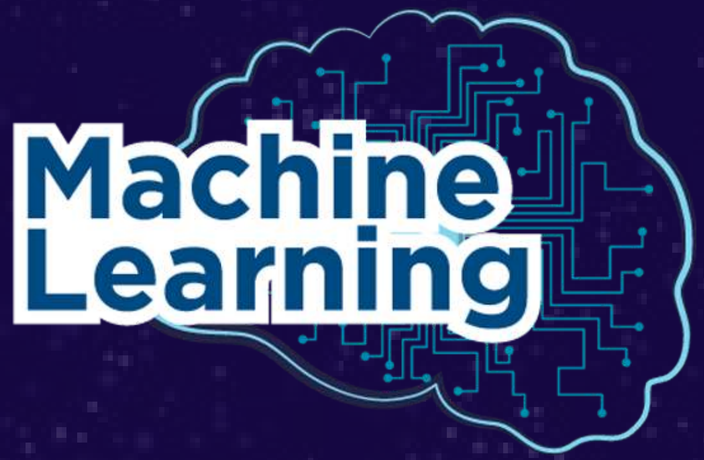
Vậy các bạn đã sẵn sàng để làm việc với dữ liệu văn bản chưa? 🚀

02

NLP và ML - DL

Sự Khác Biệt Giữa NLP, Machine Learning (ML) Và Deep Learning (DL)

Machine Learning (ML): dạy máy học từ dữ liệu





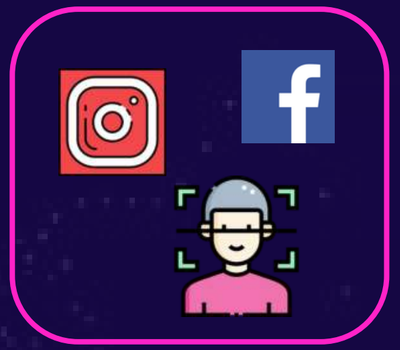
Deep Learning (DL): sử dụng mạng nơ-ron sâu (neural networks) để học từ dữ liệu lớn (dữ liệu có nhiều chiều).



NLP: Là ứng dụng của ML/DL cho ngôn ngữ.

NLP

Khi chưa ứng dụng các kỹ thuật NLP



Chưa có các tính năng phân tích bình luận, hoặc review trên các trang mạng xã hội



Phân tích văn bản thủ công





Dịch thuật cần phiên dịch viên

CYBERSOFT
CHUYÊN GIA LẬP TRÌNH

Ứng dụng NLP trong cuộc sống



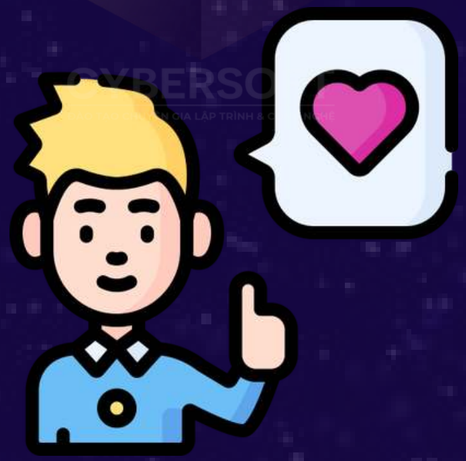
Phân Tích Cảm Xúc, đánh tag content trên mạng xã hội (Sentiment Analysis)



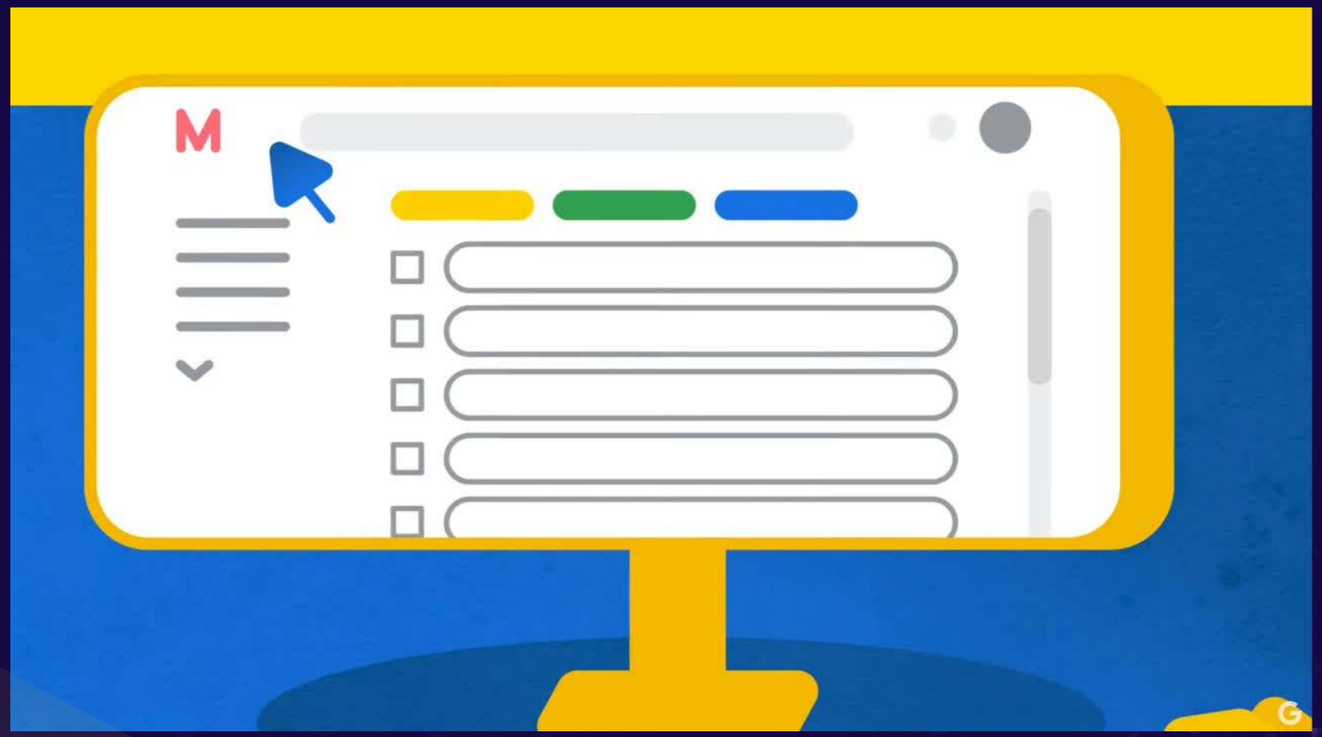
Dịch Máy (Machine Translation)



Trích Xuất Thông Tin (Information Extraction)



Phân loại email (Spam Filtering) ứng dụng Supervised Learning



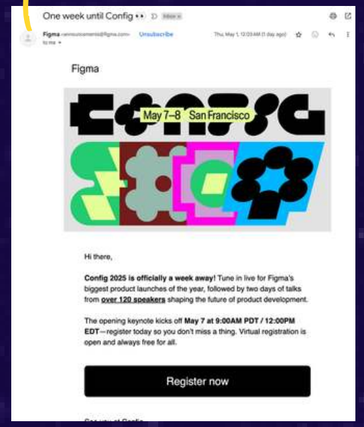
Spam

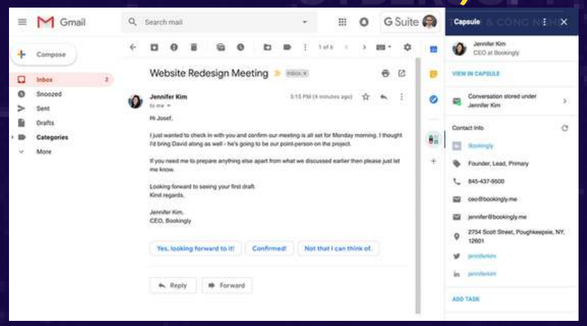
nhãn (label)

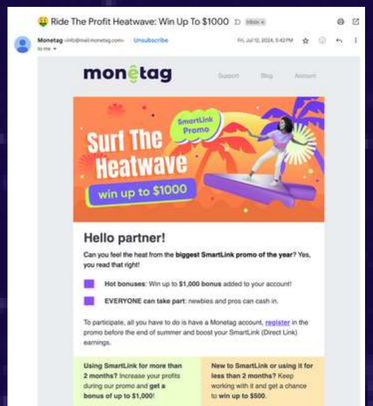
Not Spam

training Supervised

Prediction







CYBERSOFT

Phân loại Email Spam

Category	Message
ham	Go until jurong point, crazy.. Available only in bugis n great world la e buffet... Cine there got amore wat...
spam	Free entry in 2 a wkly comp to win FA Cup final tkts 21st May 2005. Text FA to 87121 to receive entry question(std txt rate)T&C's apply 08452810075over18's
ham	Even my brother is not like to speak with me. They treat me like aids patent.
spam	SIX chances to win CASH! From 100 to 20,000 pounds txt> CSH11 and send to 87575. Cost 150p/day, 6days, 16+ TsandCs apply Reply HL 4 info

Ta có một datasets danh sách các email trong hộp thư đến. Mỗi email đều được đánh dấu là Spam hoặc Ham. Dự đoán xem là nếu lần tiếp theo nhận được một email thì email đó có phải là spam không?

Các bước thực hiện

1. Cài đặt thư viện
2. Import thư viện
3. Đọc dữ liệu
4. Tách dữ liệu
5. Tiền xử lý dữ liệu
6. Chia bộ dữ liệu
7. Huấn luyện mô hình
8. Đánh giá dữ liệu
9. Thực hiện dự đoán
10. Lưu mô hình

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Kết quả

```
new_email = "Free entry in 2 a wkly comp to win FA Cup final tkts"
processed_email = advanced_preprocess(new_email)
pred = text_clf.predict([processed_email])
print("Dự đoán:", "Spam" if pred[0] == 1 else "Ham")
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

```
Dự đoán: Spam
```

Ứng dụng NLP trong TMĐT & Marketing

amazon



Phân tích cảm xúc (sentiment analysis) từ review sản phẩm



Đề xuất sản phẩm



Tối ưu hóa tìm kiếm.

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Ứng dụng NLP trong Y tế





Trích xuất thông tin từ bệnh án



Phân tích ghi chú bác sĩ

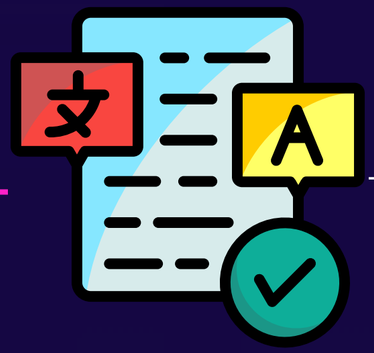


Hỗ trợ chẩn đoán

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Ứng dụng NLP trong Truyền Thông và Báo Chí





Tóm tắt bài báo



Phân tích ghi chú bác sĩ



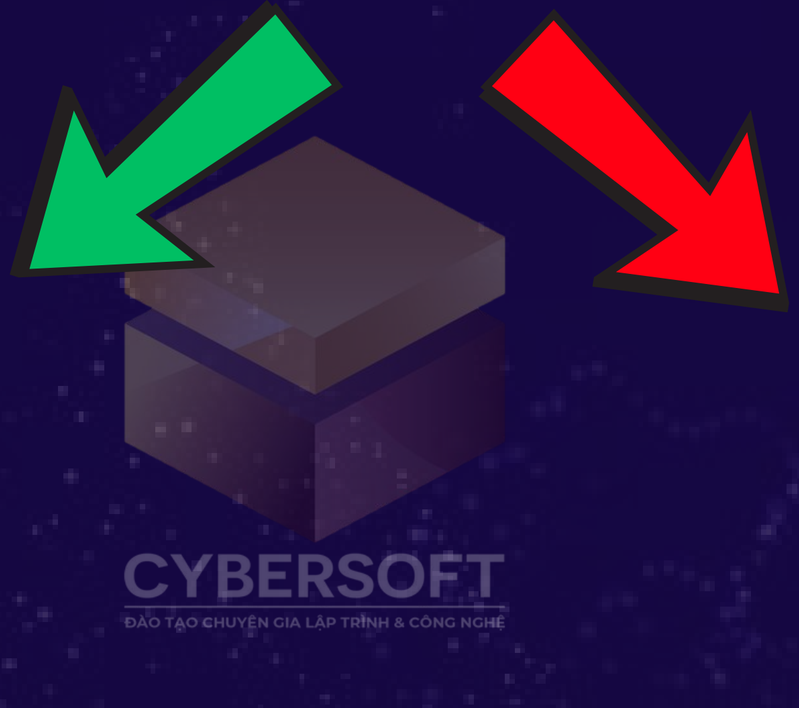
Hỗ trợ chẩn đoán

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Bài toán - Phân tích cảm xúc khách hàng

Nhận xét của khách hàng







POSITIVE

NEGATIVE

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Natural Language Processing

Mục tiêu: Dùng NLP để đánh giá sự hài lòng của khách hàng (tích cực hoặc tiêu cực) thông qua các kỹ thuật tiền xử lý văn bản cơ bản





CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ



POSITIVE

NEGATIVE

Natural Language Processing

“I loved this movie and will watch it again”



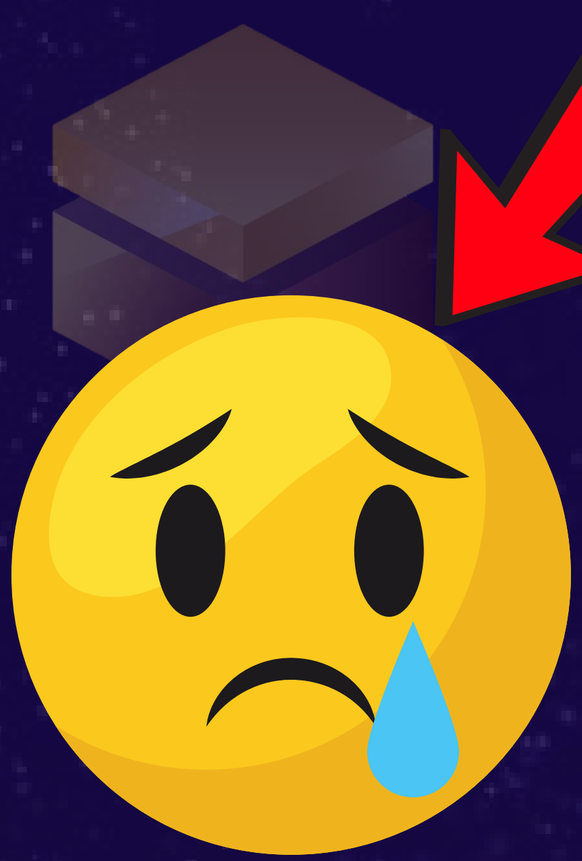
Natural Language Processing

Bước 1	Bước 2	Bước 3	Bước 4	Bước 5
I				
loved	loved	love	love	
this				
movie	movie	movie	movie	
and				
will				
watch	watch	watch	watch	
it				
again				

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH CÔNG NGHỆ

Natural Language Processing

“This movie is so boring”

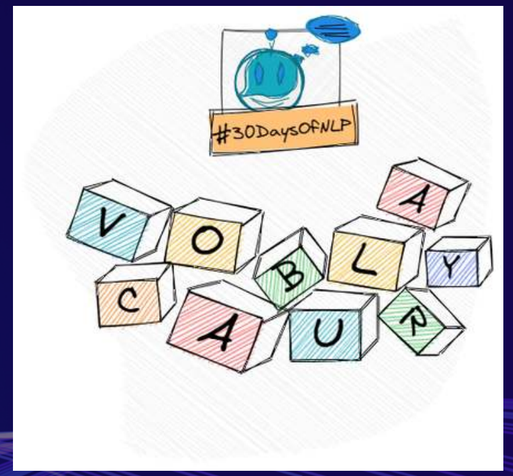


CÁC KỸ THUẬT XỬ LÝ VĂN BẢN







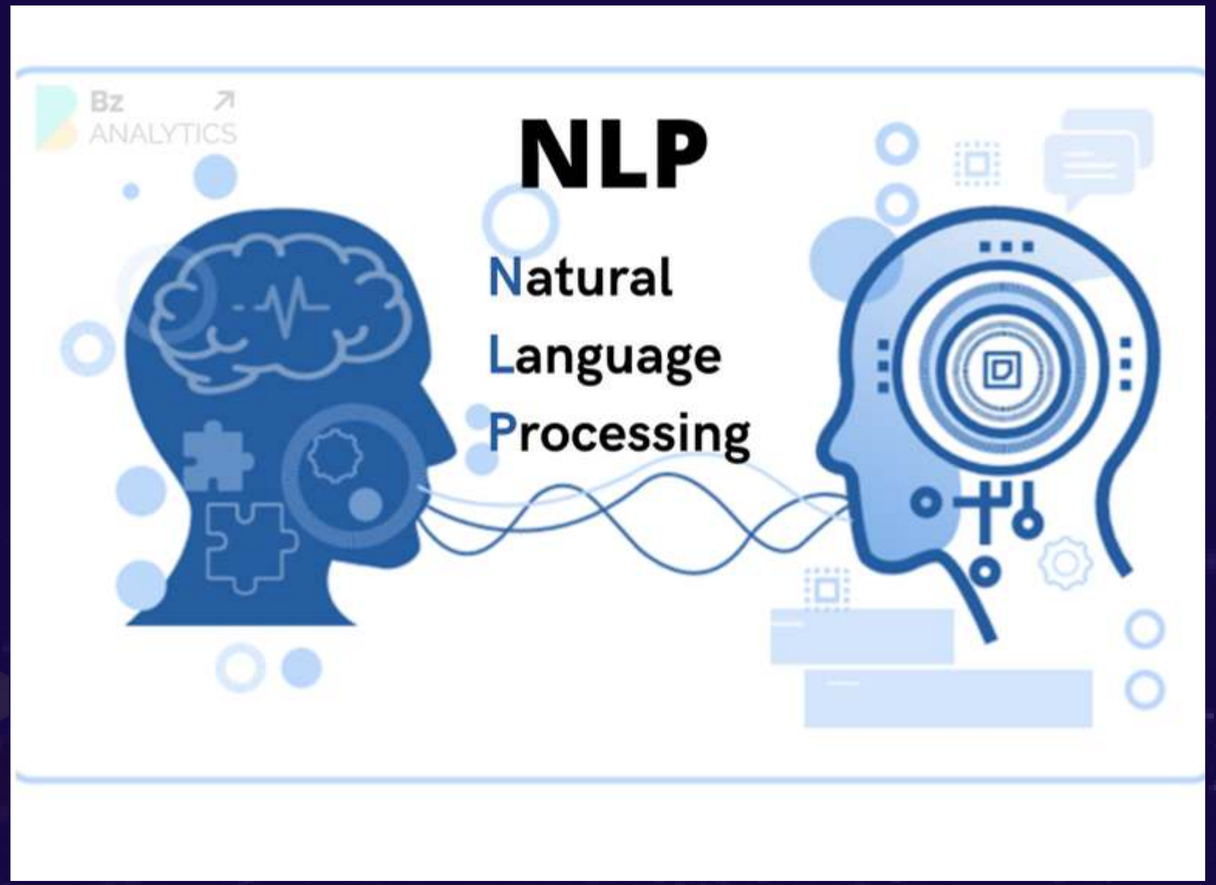




Làm quen với NLP

Định nghĩa NLP

- Natural Language Processing (NLP) là một lĩnh vực con của AI, tập trung vào việc giúp máy tính hiểu, diễn giải và tạo ra ngôn ngữ tự nhiên của con người.
- NLP kết hợp giữa khoa học máy tính, trí tuệ nhân tạo và ngôn ngữ học.
- Ví dụ: Khi bạn nói "Hey Siri, thời tiết hôm nay thế nào?", NLP giúp Siri phân tích câu hỏi, trích xuất ý nghĩa và trả lời.



- Phân loại văn bản
- Trích xuất thông tin
- Dịch máy (machine translation): Google Translate.
- Phân tích cảm xúc (sentiment analysis): Phân tích review khách hàng.

Python Regular Expressions (Regex)

Tìm kiếm và thao tác chuỗi dựa trên mẫu (pattern).

My telephone number is 408-555-1234



My telephone number is 408-555-1234



408-555-1234

CYBERSOFT

Python Regular Expressions (Regex)

Tìm kiếm và thao tác chuỗi dựa trên mẫu (pattern).

Trích xuất thông tin (Tìm kiếm SĐT)

My telephone number is 408-555-1234



My telephone number is 408-555-1234



408-555-1234

CYBERSOFT

Python Regular Expressions (Regex)

Tìm kiếm và thao tác chuỗi dựa trên mẫu (pattern).

Xác định vị trí từ (catfish)

Hello, would you like some catfish?



Hello, would you like some catfish?

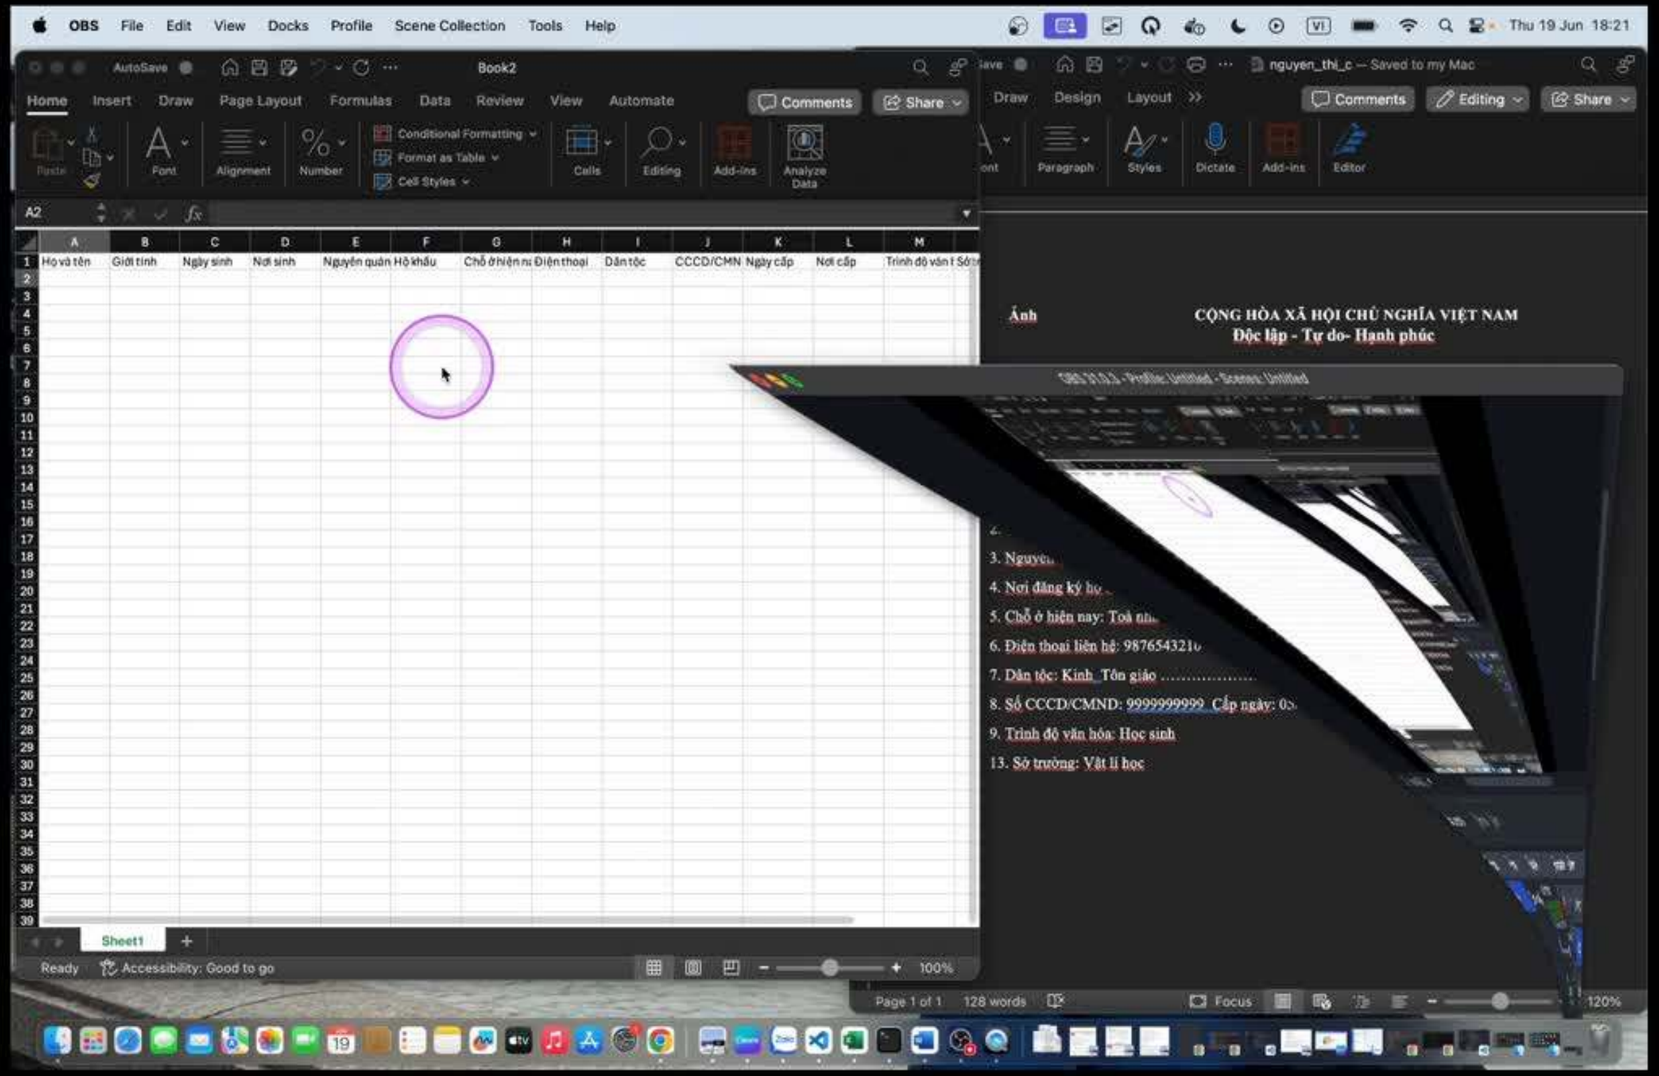


Index 27 - 34

CYBERSOFT
TẠO CHUYÊN GIA LẬP TRÌNH

Python Regular Expressions (Regex)

Tìm kiếm và thao tác chuỗi dựa trên mẫu (pattern).



Spacy & NLTK

Tiền xử lý (preprocessing) là bước quan trọng nhất trong NLP, chiếm 70-80% thời gian dự án.

Văn bản thô có nhiễu (ký tự lạ, lỗi chính tả), cần chuẩn hóa để mô hình học hiệu quả.



Cổ điển, dễ dùng cho tokenization, stemming



Tiên tiến, nhanh, hỗ trợ lemmatization và NER (Named Entity Recognition)

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Spacy & NLTK

Spacy trong Python



```python
# Import spaCy and load the language library
import spacy
nlp = spacy.load('en_core_web_sm')

# Create a Doc object
doc = nlp(u'Tesla is looking at buying U.S. startup for $6 million')

# Print each token separately
for token in doc:
    print(token.text, token.pos_, token.dep_)
```

```
Tesla PROPN nsubj
is VERB aux
looking VERB ROOT
at ADP prep
buying VERB pcomp
U.S. PROPN compound
startup NOUN dobj
for ADP prep
$ SYM quantmod
6 NUM compound
million NUM pobj
```

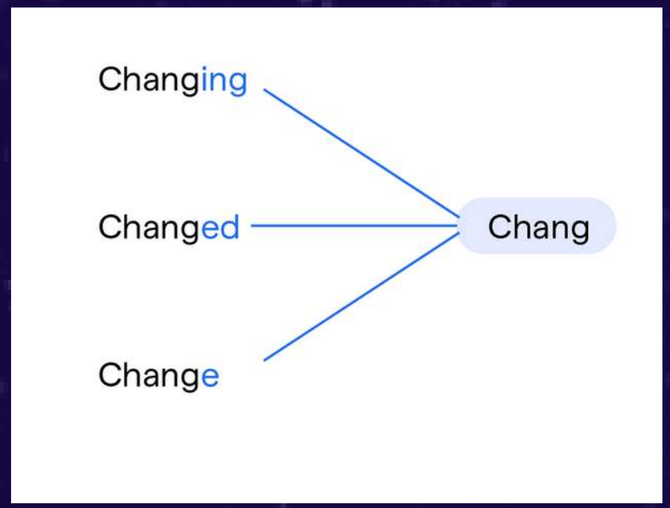
Tokenization

Chia văn bản thô thành các đơn vị nhỏ hơn, gọi là token.



WE LOVE NLP!

[0.17, 0.35, 0.28]



Token có thể là từ, cụm từ, câu, hoặc thậm chí ký tự

BERSOFT
CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Tokenization

Cách tokenization hoạt động (Python code)




```python
# Import spaCy and load the language library
import spacy

nlp = spacy.load('en_core_web_sm')
# Create a string that includes opening and closing quotation marks
mystring = '"We\'re moving to L.A.!"'
# Create a Doc object and explore tokens
doc = nlp(mystring)

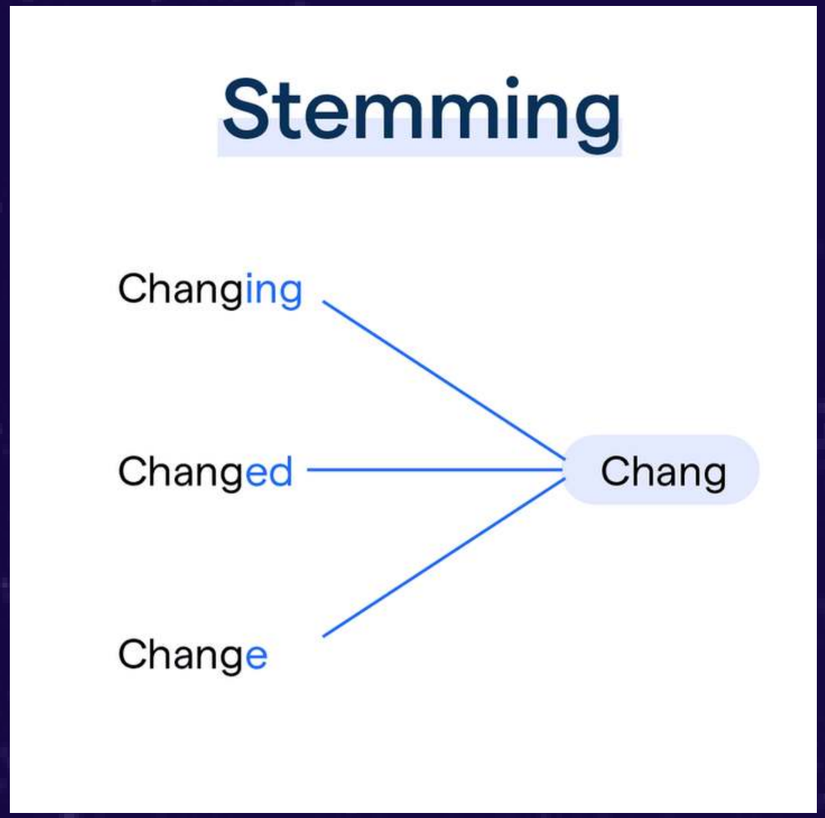
for token in doc:
    print(token.text, end=' | ')
```

```
" | We | 're | moving | to | L.A. | ! | " |
```

Stemming

Chuyển từ về dạng gốc (Stem)

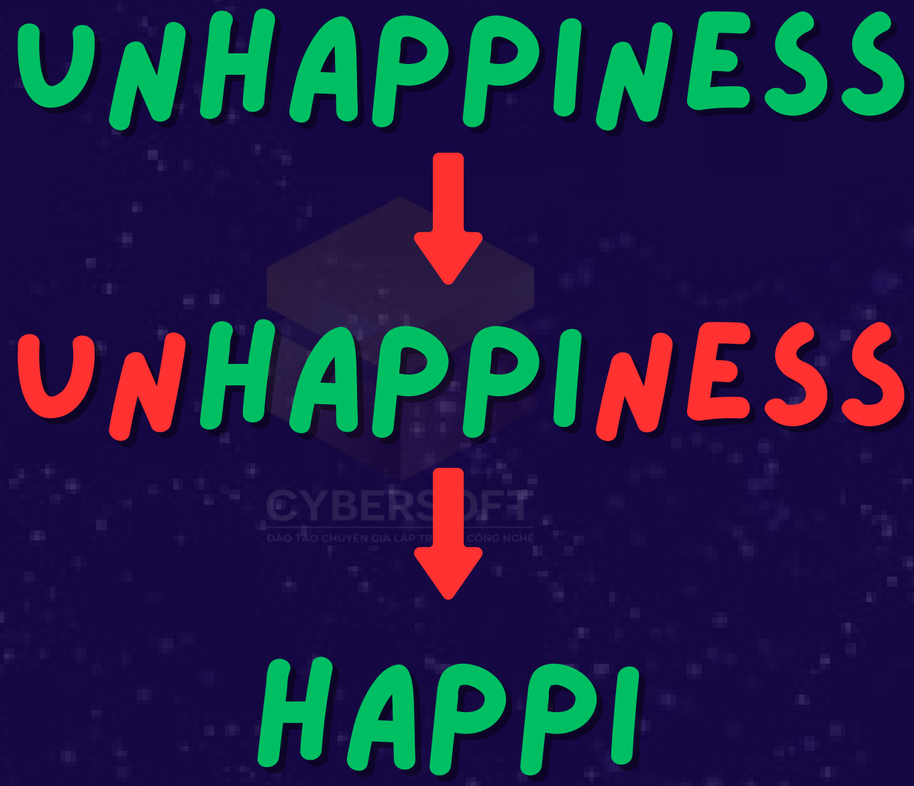
PREFIXES



SUFFIXES

Stemming

Chuyển từ về dạng gốc (Stem)



CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH CÔNG NGHỆ

Stemming

Mục đích





Stemming

Mục đích → Giảm kích thước từ vựng
Giữ ý nghĩa ngữ cảnh





CYBERSO
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH

Stemming

Cách Stemming hoạt động

PORTER

```
from nltk.stem.porter import *

p_stemmer = PorterStemmer()
words = ['run','runner','running','ran','runs','easily','fairly']
for word in words:
    print(word+' --> '+p_stemmer.stem(word))
```




```
from nltk.stem.snowball import SnowballStemmer

# SnowballStemmer yêu cầu truyền vào một tham số là ngôn ngữ
p_stemmer = SnowballStemmer(language='english')
words = ['run','runner','running','ran','runs','easily','fairly']
for word in words:
    print(word+' --> '+p_stemmer.stem(word))
```

Lemmatization

Stemming



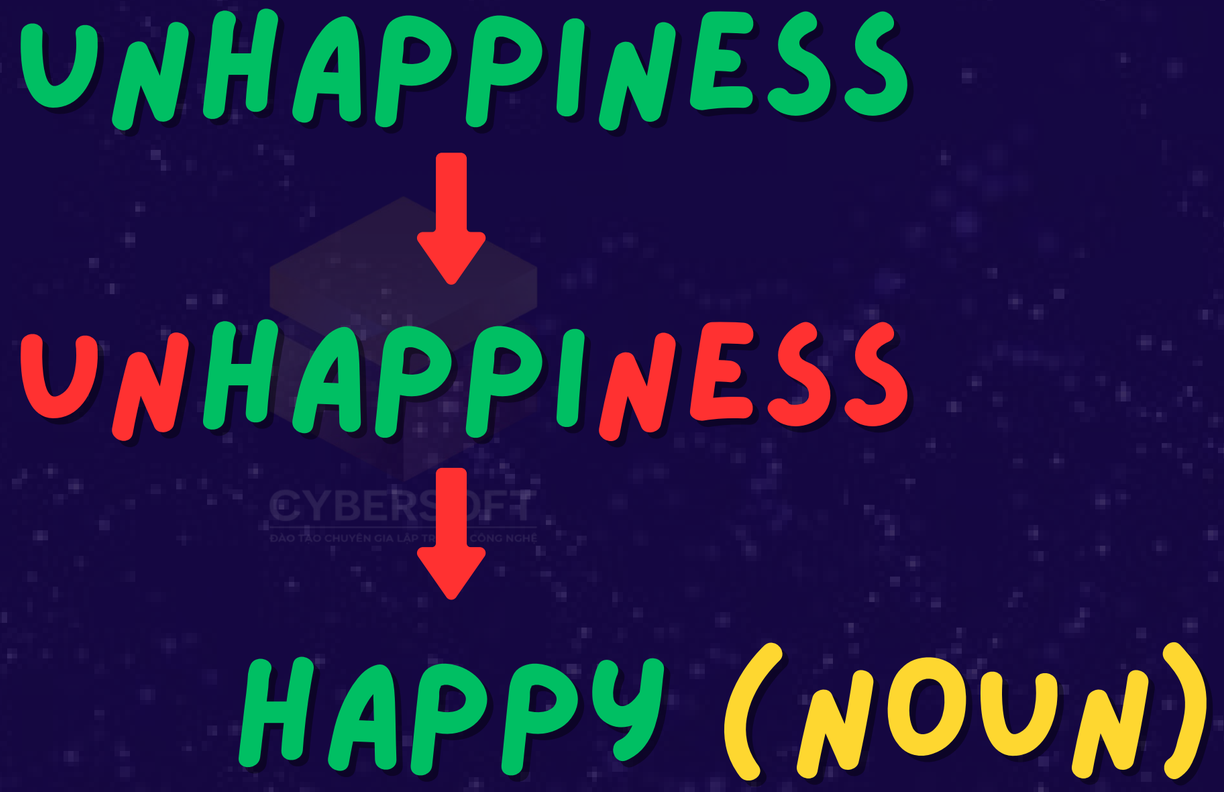
Lemmatization



ERSOFT
N GIA LẬP TRÌNH & CÔNG NGHỆ

Lemmatization

Chuyển từ về dạng gốc (Lemma)



CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH CÔNG NGHỆ

Vocab-matching

Matching từ khóa từ vocabulary để phân loại

Positive Vocabs

- love, great
- excellent, good, well
- best
- happy

Negative Vocabs

- hate, bad
- worst
- terrible
- sad, boring

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Vocab-matching

Matching từ khóa từ vocabulary để phân loại

"I loved this movie and will watch it again"

1

0

Positive Vocabs

- love, great
- excellent, good, well
- best
- happy

Negative Vocabs

- hate, bad
- worst
- terrible
- sad, boring

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Vocab-matching

Matching từ khóa từ vocabulary để phân loại



1

Positive Vocabs

- love, great
- excellent, good, well
- best
- happy

0

Negative Vocabs

- hate, bad
- worst
- terrible
- sad, boring

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Vocab-matching

Matching từ khóa từ vocabulary để phân loại

"This movie is so boring"

0

Positive Vocabs

- love, great
- excellent, good, well
- best
- happy

1

Negative Vocabs

- hate, bad
- worst
- terrible
- sad, boring

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Vocab-matching

Matching từ khóa từ vocabulary để phân loại



0

Positive Vocabs

- love, great
- excellent, good, well
- best
- happy

1

Negative Vocabs

- hate, bad
- worst
- terrible
- sad, boring

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

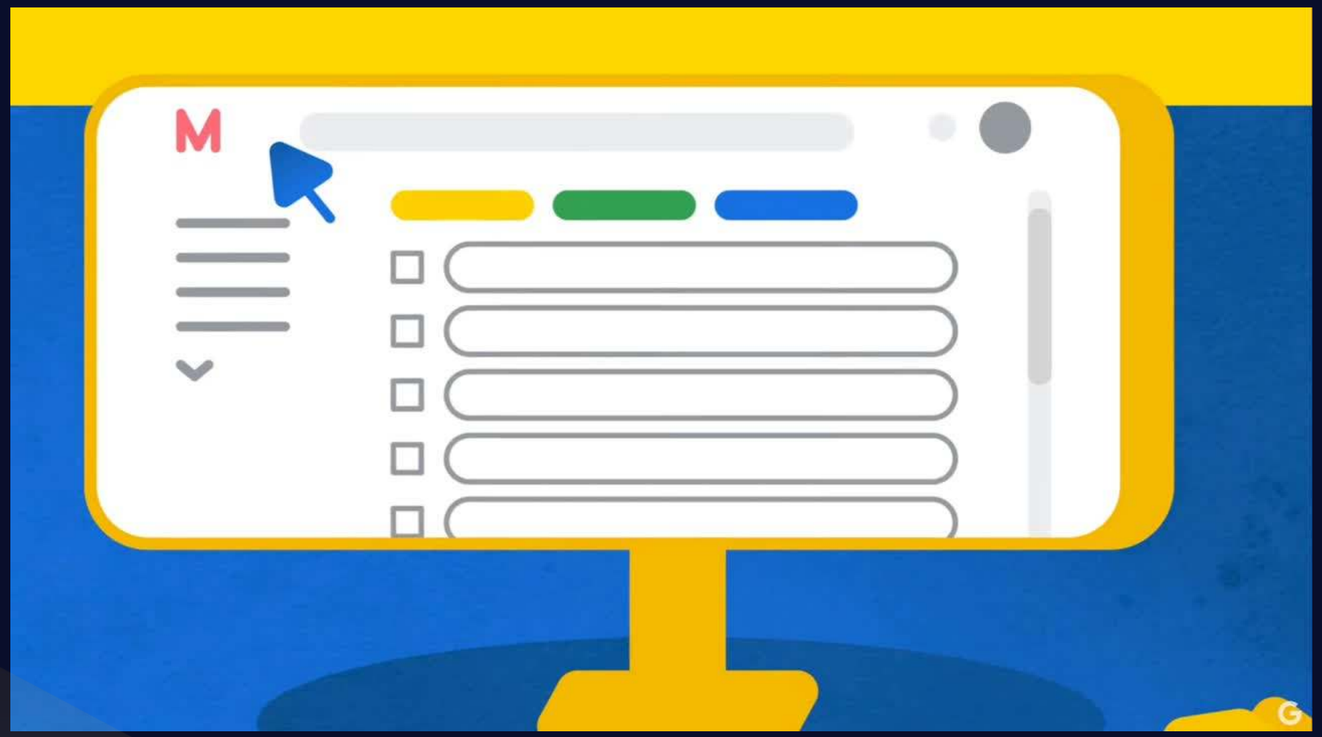


Bài tập thực hành

Làm quen với xử lý ngôn ngữ tự nhiên

Phân loại Email Spam

Phân loại email (Spam Filtering) ứng dụng Supervised Learning



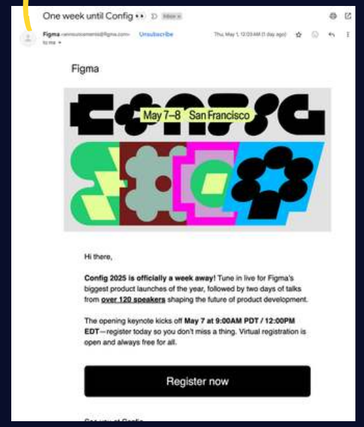
Spam

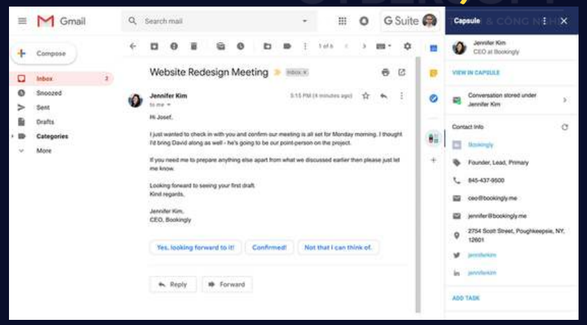
nhãn (label)

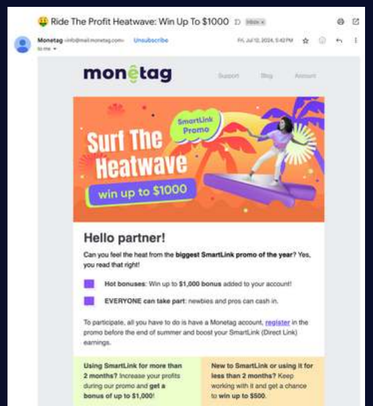
Not Spam

training Supervised

Prediction







CYBERSOFT

Các bước thực hiện

1. Cài đặt thư viện
2. Import thư viện
3. Đọc dữ liệu
4. Tách dữ liệu
5. Tiền xử lý dữ liệu
6. Chia bộ dữ liệu
7. Huấn luyện mô hình
8. Đánh giá mô hình
9. Thực hiện dự đoán
10. Lưu mô hình

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Import thư viện

```
import string
import nltk
nltk.download('stopwords')
nltk.download('punkt')
nltk.download('punkt_tab')
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import MultinomialNB
from sklearn.metrics import accuracy_score
from sklearn.preprocessing import LabelEncoder
```

Đọc dữ liệu

```
DATASET_PATH = '/content/cls_spam_text.csv'
df = pd.read_csv(DATASET_PATH)
df
```

	Category	Message
0	ham	Go until jurong point, crazy.. Available only ...
1	ham	Ok lar... Joking wif u oni...
2	spam	Free entry in 2 a wkly comp to win FA Cup fina...
3	ham	U dun say so early hor... U c already then say...
4	ham	Nah I don't think he goes to usf, he lives aro...

Tách dữ liệu

```
messages = df['Message'].values.tolist()
labels = df['Category'].values.tolist()
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Tách dữ liệu

```
messages = df['Message'].values.tolist()
labels = df['Category'].values.tolist()
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Xử lý dữ liệu

Xử lý dữ liệu nhãn

```
le = LabelEncoder()
y = le.fit_transform(labels)
print(f'Classes: {le.classes_}')
print(f'Encoded labels: {y}')
```

```
Classes: ['ham' 'spam']
Encoded labels: [0 0 1 ... 0 0 0]
```

Xử lý dữ liệu

Các hàm xử lý dữ liệu đặc trưng

```
def lowercase(text):
    return text.lower()

def punctuation_removal(text):
    translator = str.maketrans('', '', string.punctuation)

    return text.translate(translator)

def tokenize(text):
    return nltk.word_tokenize(text)

def remove_stopwords(tokens):
    stop_words = nltk.corpus.stopwords.words('english')

    return [token for token in tokens if token not in stop_words]

def stemming(tokens):
    stemmer = nltk.PorterStemmer()

    return [stemmer.stem(token) for token in tokens]
```

Xử lý dữ liệu

Hàm xử lý chính

```python
def preprocess_text(text):
    text = lowercase(text)
    text = punctuation_removal(text)
    tokens = tokenize(text)
    tokens = remove_stopwords(tokens)
    tokens = stemming(tokens)

    return tokens
```

```python
messages = [
    preprocess_text(message) for message in messages
]
```



Viết thường → Xoá các dấu ngắt câu → Tách các từ trong câu → Xoá các từ a, an, the → Chuyển từ về dạng chuẩn

Xử lý dữ liệu

Hàm tạo từ điển

```
def create_dictionary(messages):
    dictionary = []

    for tokens in messages:
        for token in tokens:
            if token not in dictionary:
                dictionary.append(token)

    return dictionary
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Hàm này dùng để xây dựng một **bộ từ vựng (vocabulary)** từ tập dữ liệu văn bản. Từ vựng này là tập hợp **tất cả các từ (hoặc token)** độc đáo xuất hiện trong dữ liệu, loại bỏ lặp lại.

Xử lý dữ liệu

Hàm tạo tạo vector đặc trưng

```
def create_features(tokens, dictionary):
    features = np.zeros(len(dictionary))

    for token in tokens:
        if token in dictionary:
            features[dictionary.index(token)] += 1

    return features
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Hàm này dùng để chuyển đổi văn bản thành **vector đặc trưng** dựa trên từ vựng đã có.

Xử lý dữ liệu

Hàm tạo tạo vector đặc trưng

```
def create_features(tokens, dictionary):
    features = np.zeros(len(dictionary))

    for token in tokens:
        if token in dictionary:
            features[dictionary.index(token)] += 1

    return features
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Đây là một dạng biểu diễn văn bản đơn giản gọi là **Bag-of-Words (BoW)**, nơi mỗi văn bản được biểu diễn bằng một vector đếm số lần xuất hiện của từng từ trong từ vựng

Xử lý dữ liệu

Hàm tạo từ điển và vector đặc trưng

```
dictionary = create_dictionary(messages)
X = np.array(
    [create_features(tokens, dictionary) for tokens in messages]
)
```

```
X[0]
```

```
array([1., 1., 1., ..., 0., 0., 0.])
```

Chia bộ dữ liệu

Chia dữ liệu thành các tập train/test/val

```
VAL_SIZE = 0.2
TEST_SIZE = 0.125
SEED = 0

X_train, X_val, y_train, y_val = train_test_split(
    X, y,
    test_size=VAL_SIZE,
    shuffle=True,
    random_state=SEED
)
X_train, X_test, y_train, y_test = train_test_split(
    X_train, y_train,
    test_size=TEST_SIZE,
    shuffle=True,
    random_state=SEED
)
```

Huấn luyện mô hình

Multinomial Naive Bayes

```
%%time
model = MultinomialNB()
print('Start training...')
model = model.fit(X_train, y_train)
print('Training completed!')
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Multinomial Naive Bayes thường dùng cho các bài toán phân loại văn bản **(text classification)**, như phân loại **email spam**, cảm xúc **(sentiment analysis)**, hoặc phân loại tài liệu, vì nó hiệu quả với dữ liệu đếm tần suất **(như Bag-of-Words hoặc TF-IDF)**.

Huấn luyện mô hình

Multinomial Naive Bayes

```
%%time
model = MultinomialNB()
print('Start training...')
model = model.fit(X_train, y_train)
print('Training completed!')
```

CYBERSOFT

```
Start training...
Training completed!
CPU times: user 215 ms, sys: 1.26 ms, total: 216 ms
Wall time: 190 ms
```

Đánh giá mô hình

Multinomial Naive Bayes

```
y_val_pred = model.predict(X_val)
y_test_pred = model.predict(X_test)
val_accuracy = accuracy_score(y_val, y_val_pred)
test_accuracy = accuracy_score(y_test, y_test_pred)
print(f'Val accuracy: {val_accuracy}')
print(f'Test accuracy: {test_accuracy}')
```

```
Val accuracy: 0.9820627802690582
Test accuracy: 0.9802867383512545
```

Thực hiện dự đoán

Hàm predict()

```
def predict(text, model, dictionary):
    processed_text = preprocess_text(text)
    features = create_features(text, dictionary)
    features = np.array(features).reshape(1, -1)
    prediction = model.predict(features)
    prediction_cls = le.inverse_transform(prediction)[0]

    return prediction_cls
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Thực hiện dự đoán

Thử nghiệm với input bất kỳ

```
def predict(text, model, dictionary):
    processed_text = preprocess_text(text)
    features = create_features(text, dictionary)
    features = np.array(features).reshape(1, -1)
    prediction = model.predict(features)
    prediction_cls = le.inverse_transform(prediction)[0]

    return prediction_cls
```

CYBERSOFT

```
test_input = 'I am actually thinking a way of doing something useful'
prediction_cls = predict(test_input, model, dictionary)
print(f'Prediction: {prediction_cls}')
```



Bài tập thực hành

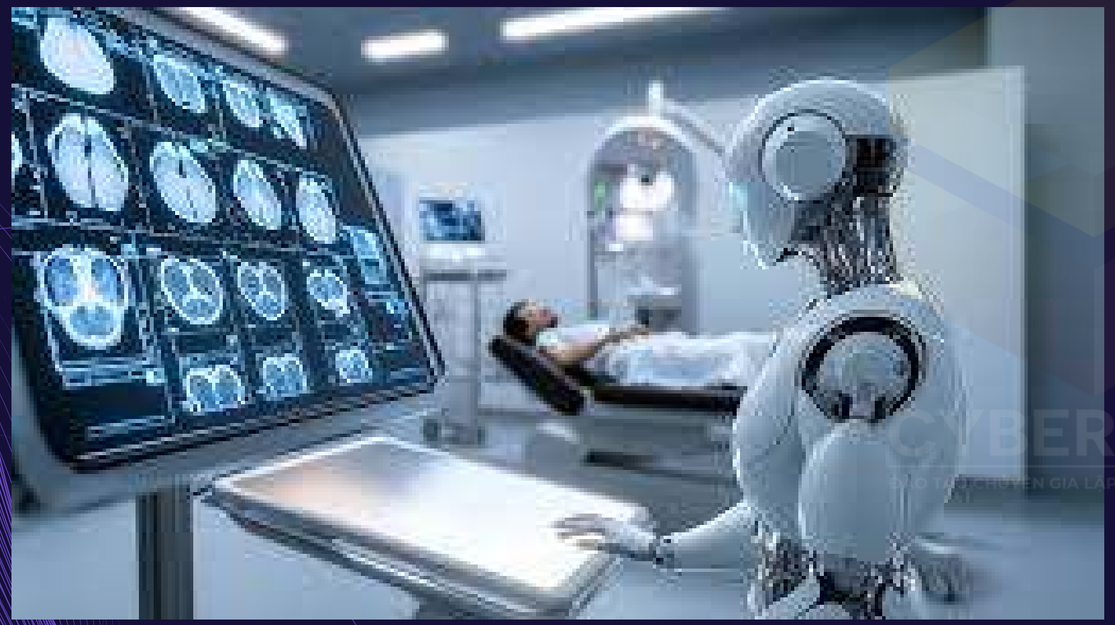
Làm quen với xử lý ngôn ngữ tự nhiên

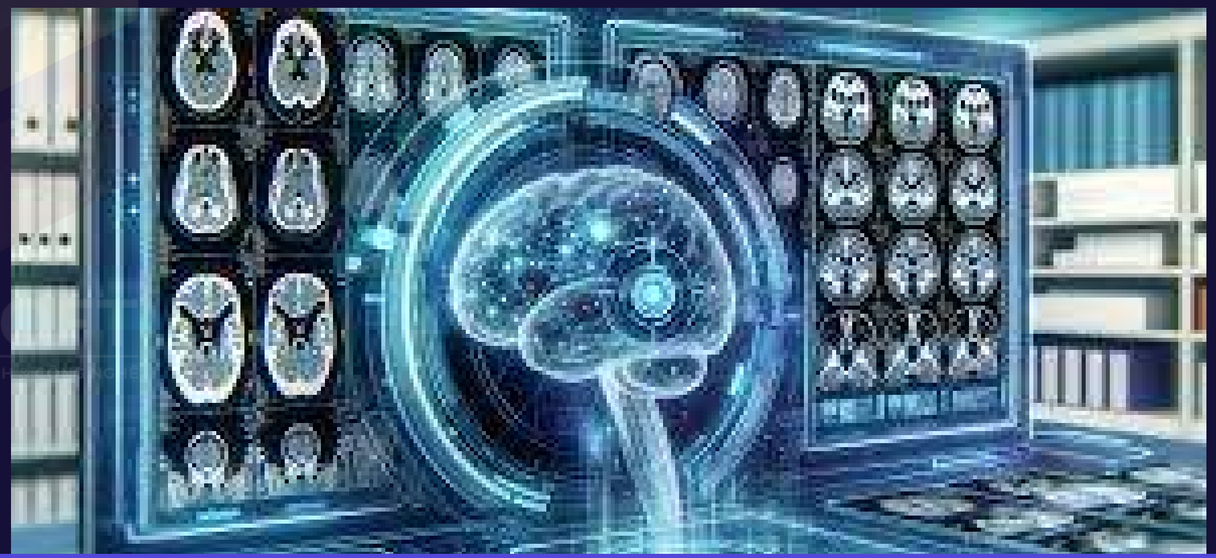
Phân loại cảm xúc #1

CYBERSOFT

Bài tập thực hành

LÀM QUEN VỚI XỬ LÝ NGÔN NGỮ TỰ NHIÊN





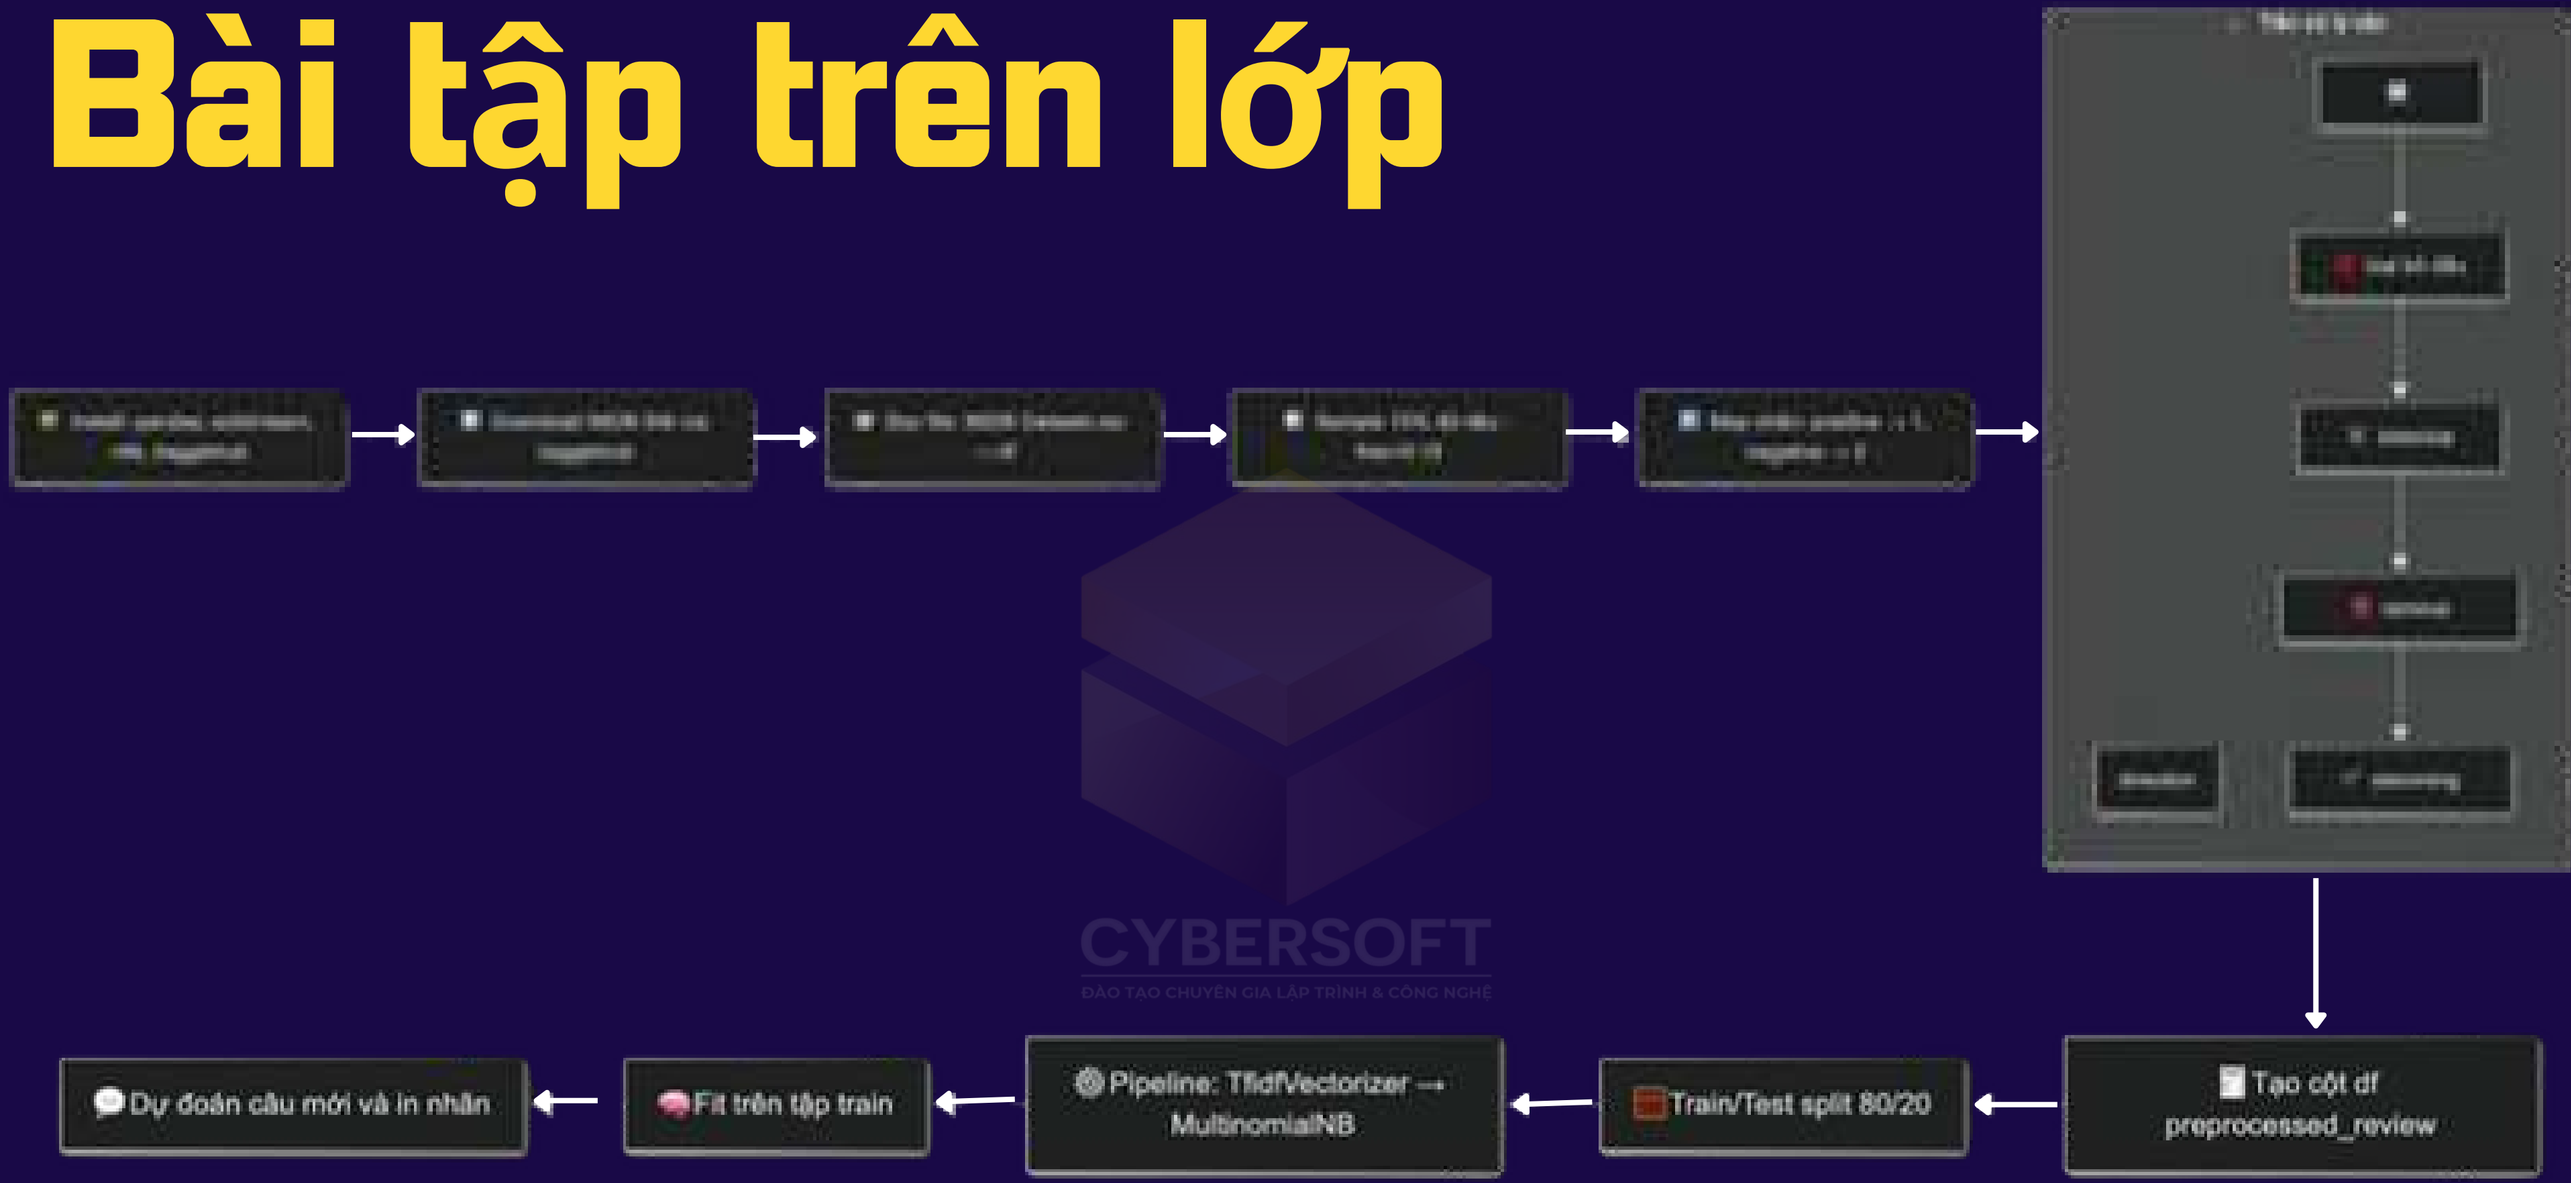
Bài tập thực hành

CÔNG NGHỆ & FRAMEWORK





Bài tập trên lớp



CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Các bước thực hiện

1. Cài đặt thư viện
2. Import thư viện
3. Tải datasets
4. Tiền xử lý dữ liệu
5. Phân loại dựa trên dữ liệu thực tế

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH

Làm quen với xử lý ngôn ngữ tự nhiên

1. Cài đặt thư viện

```
!pip install pandas scikit-learn nltk kagglehub
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Làm quen với xử lý ngôn ngữ tự nhiên

2. Import thư viện

```
import kagglehub
import shutil
import warnings
```

```
import nltk
nltk.download('punkt')
nltk.download('stopwords')
nltk.download('wordnet')
nltk.download('punkt_tab')
import pandas as pd
import re
from nltk.corpus import stopwords
from nltk.stem import WordNetLemmatizer
from nltk.tokenize import word_tokenize
from sklearn.preprocessing import LabelEncoder
from sklearn.metrics import accuracy_score
```

CYBERSOFT

```
from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import MultinomialNB
from sklearn.metrics import accuracy_score, f1_score, classification_report, confusion_matrix, ConfusionMatrixDisplay
from sklearn.preprocessing import LabelEncoder
from sklearn.pipeline import Pipeline
from sklearn.feature_extraction.text import TfidfVectorizer
```

Làm quen với xử lý ngôn ngữ tự nhiên

3. Tải datasets

```
path = kagglehub.dataset_download("lakshmi25npathi/imdb-dataset-of-50k-movie-reviews")
shutil.copytree(path, "/content/", dirs_exist_ok=True)
```

```
Using Colab cache for faster access to the 'imdb-dataset-of-50k-movie-reviews' dataset.
'/content/'
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Làm quen với xử lý ngôn ngữ tự nhiên

4. Tiền xử lý dữ liệu

```
data_dir = "/content/IMDB Dataset.csv"
df = pd.read_csv(data_dir)
df.head(10)
```

	review	sentiment
0	One of the other reviewers has mentioned that ...	positive
1	A wonderful little production. The...	positive
2	I thought this was a wonderful way to spend ti...	positive
3	Basically there's a family where a little boy ...	negative
4	Petter Mattei's "Love in the Time of Money" is...	positive
5	Probably my all-time favorite movie, a story o...	positive
6	I sure would like to see a resurrection of a u...	positive
7	This show was an amazing, fresh & innovative i...	negative
8	Encouraged by the positive comments about this...	negative
9	If you like original gut wrenching laughter yo...	positive

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Làm quen với xử lý ngôn ngữ tự nhiên

4. Tiền xử lý dữ liệu

```
df['sentiment'] = df['sentiment'].map({'positive': 1, 'negative': 0})
```

```
def lowercase(text):
    return text.lower()

def puctuation_remove(text):
    return re.sub(r'[^\w\s]', '', text)

def tokenize(text):
    return nltk.word_tokenize(text)

def stopword_remove(tokens):
    stop_words = nltk.corpus.stopwords.words('english')

    return [token for token in tokens if token not in stop_words]

def stemming(tokens):
    stemmer = nltk.PorterStemmer()
    return [stemmer.stem(token) for token in tokens]

def text_preprocessing(text):
    text = lowercase(text)
    text = puctuation_remove(text)
    tokens = tokenize(text)
    tokens = stopword_remove(tokens)
    tokens = stemming(tokens)
    # text = ' '.join(tokens)
    return tokens
```

```
df['preprocessed_review'] = df['review'].apply(text_preprocessing)
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Làm quen với xử lý ngôn ngữ tự nhiên

5. Phân loại dựa trên dữ liệu thực tế

```
X_train, X_test, y_train, y_test = train_test_split(df['preprocessed_review'], df['sentiment'], test_size=0.2, random_state=42)
```

```
pipeline = Pipeline([
    ("tfidf", TfidfVectorizer()),
    ("classifier", MultinomialNB())
])

pipeline.fit(X_train, y_train)
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Xây dựng pipeline và dự đoán

```
predictions = pipeline.predict(X_test)
```

Làm quen với xử lý ngôn ngữ tự nhiên

5. Phân loại dựa trên dữ liệu thực tế

```
predictions = pipeline.predict(X_test)
cm = confusion_matrix(y_test, predictions, labels=[0, 1])
disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=['negative', 'positive'])
disp.plot()
plt.show()
```

```
predictions = pipeline.predict(["The movies is too bad"])

if predictions[0] == 0:
    print("Negative")
else:
    print("Positive")
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

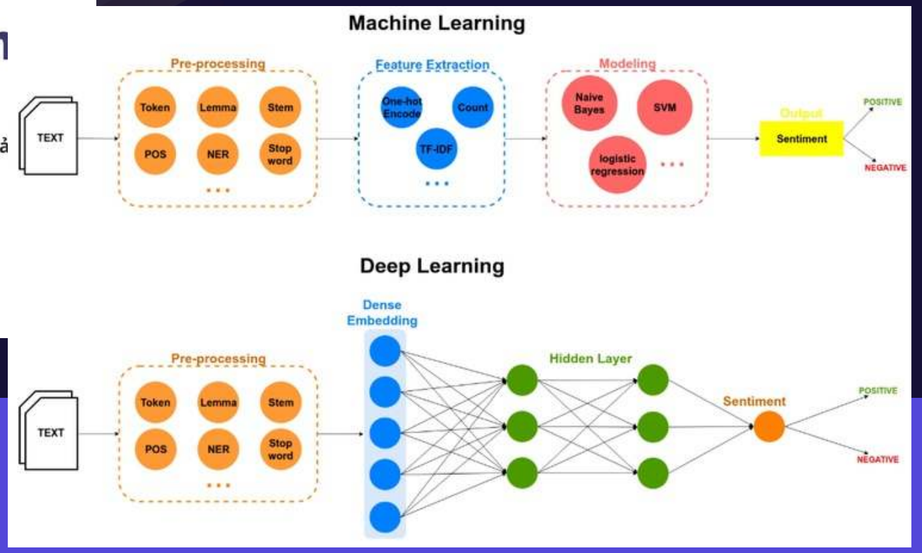


Bài tập trên lớp

Phân loại cảm xúc #2



Sentimen
Analysis
Công nghệ AI Phân tích cả



Bài tập thực hành

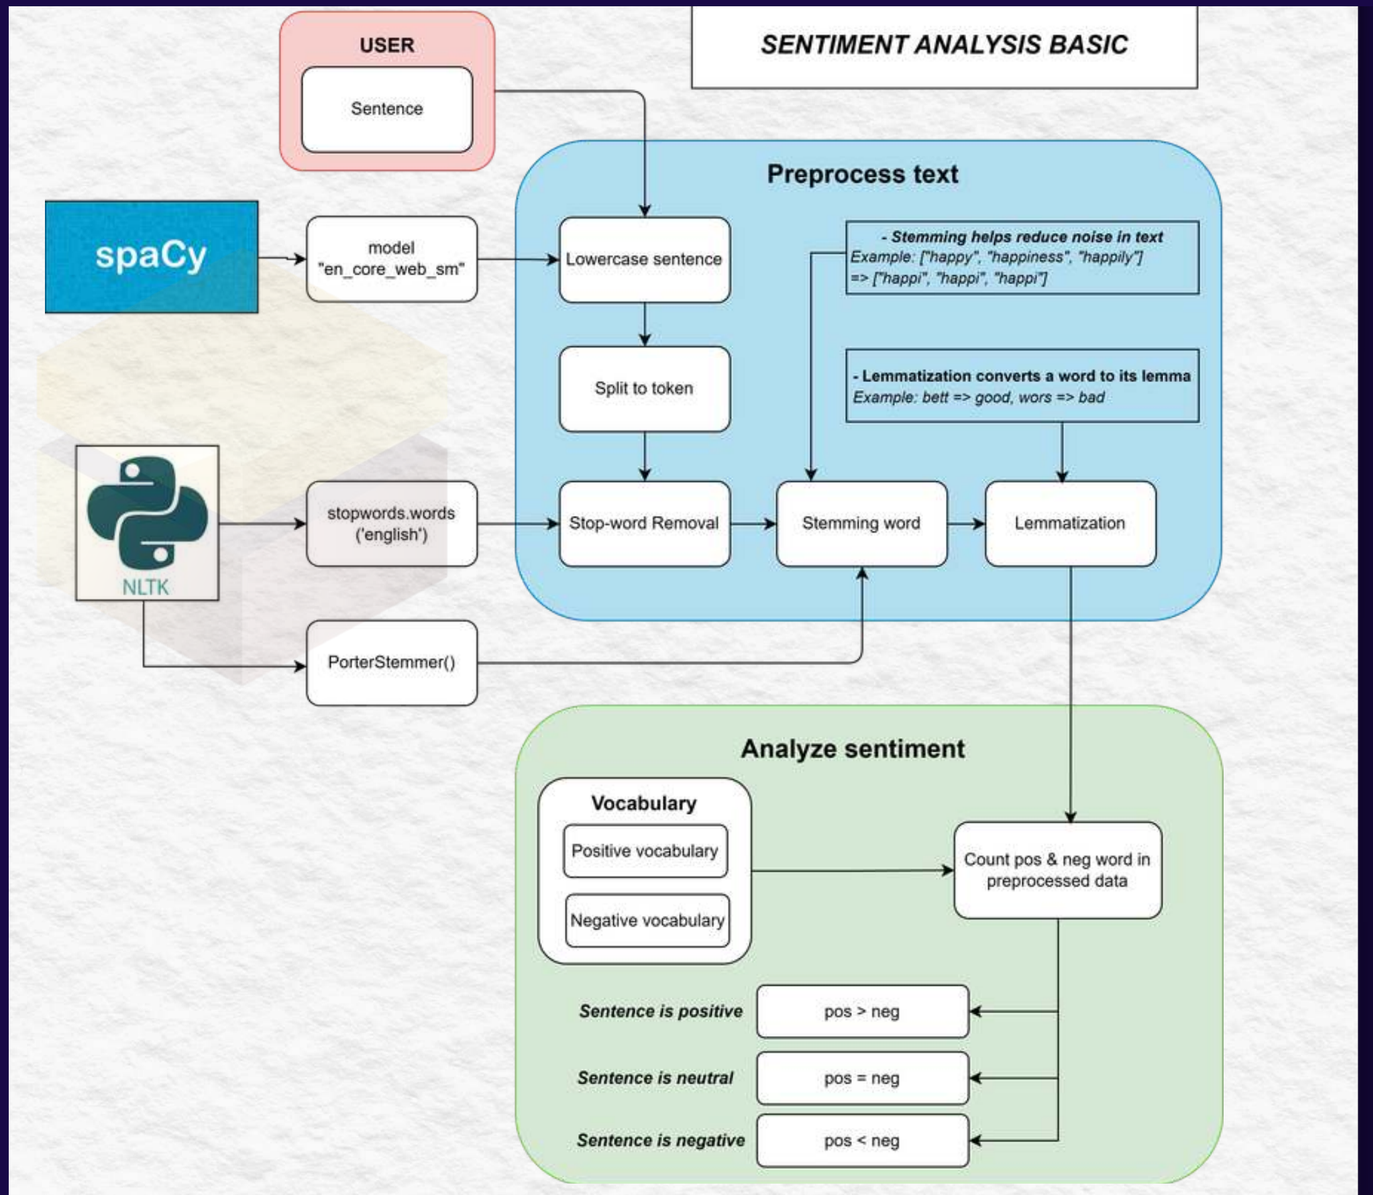
CÔNG NGHỆ & FRAMEWORK



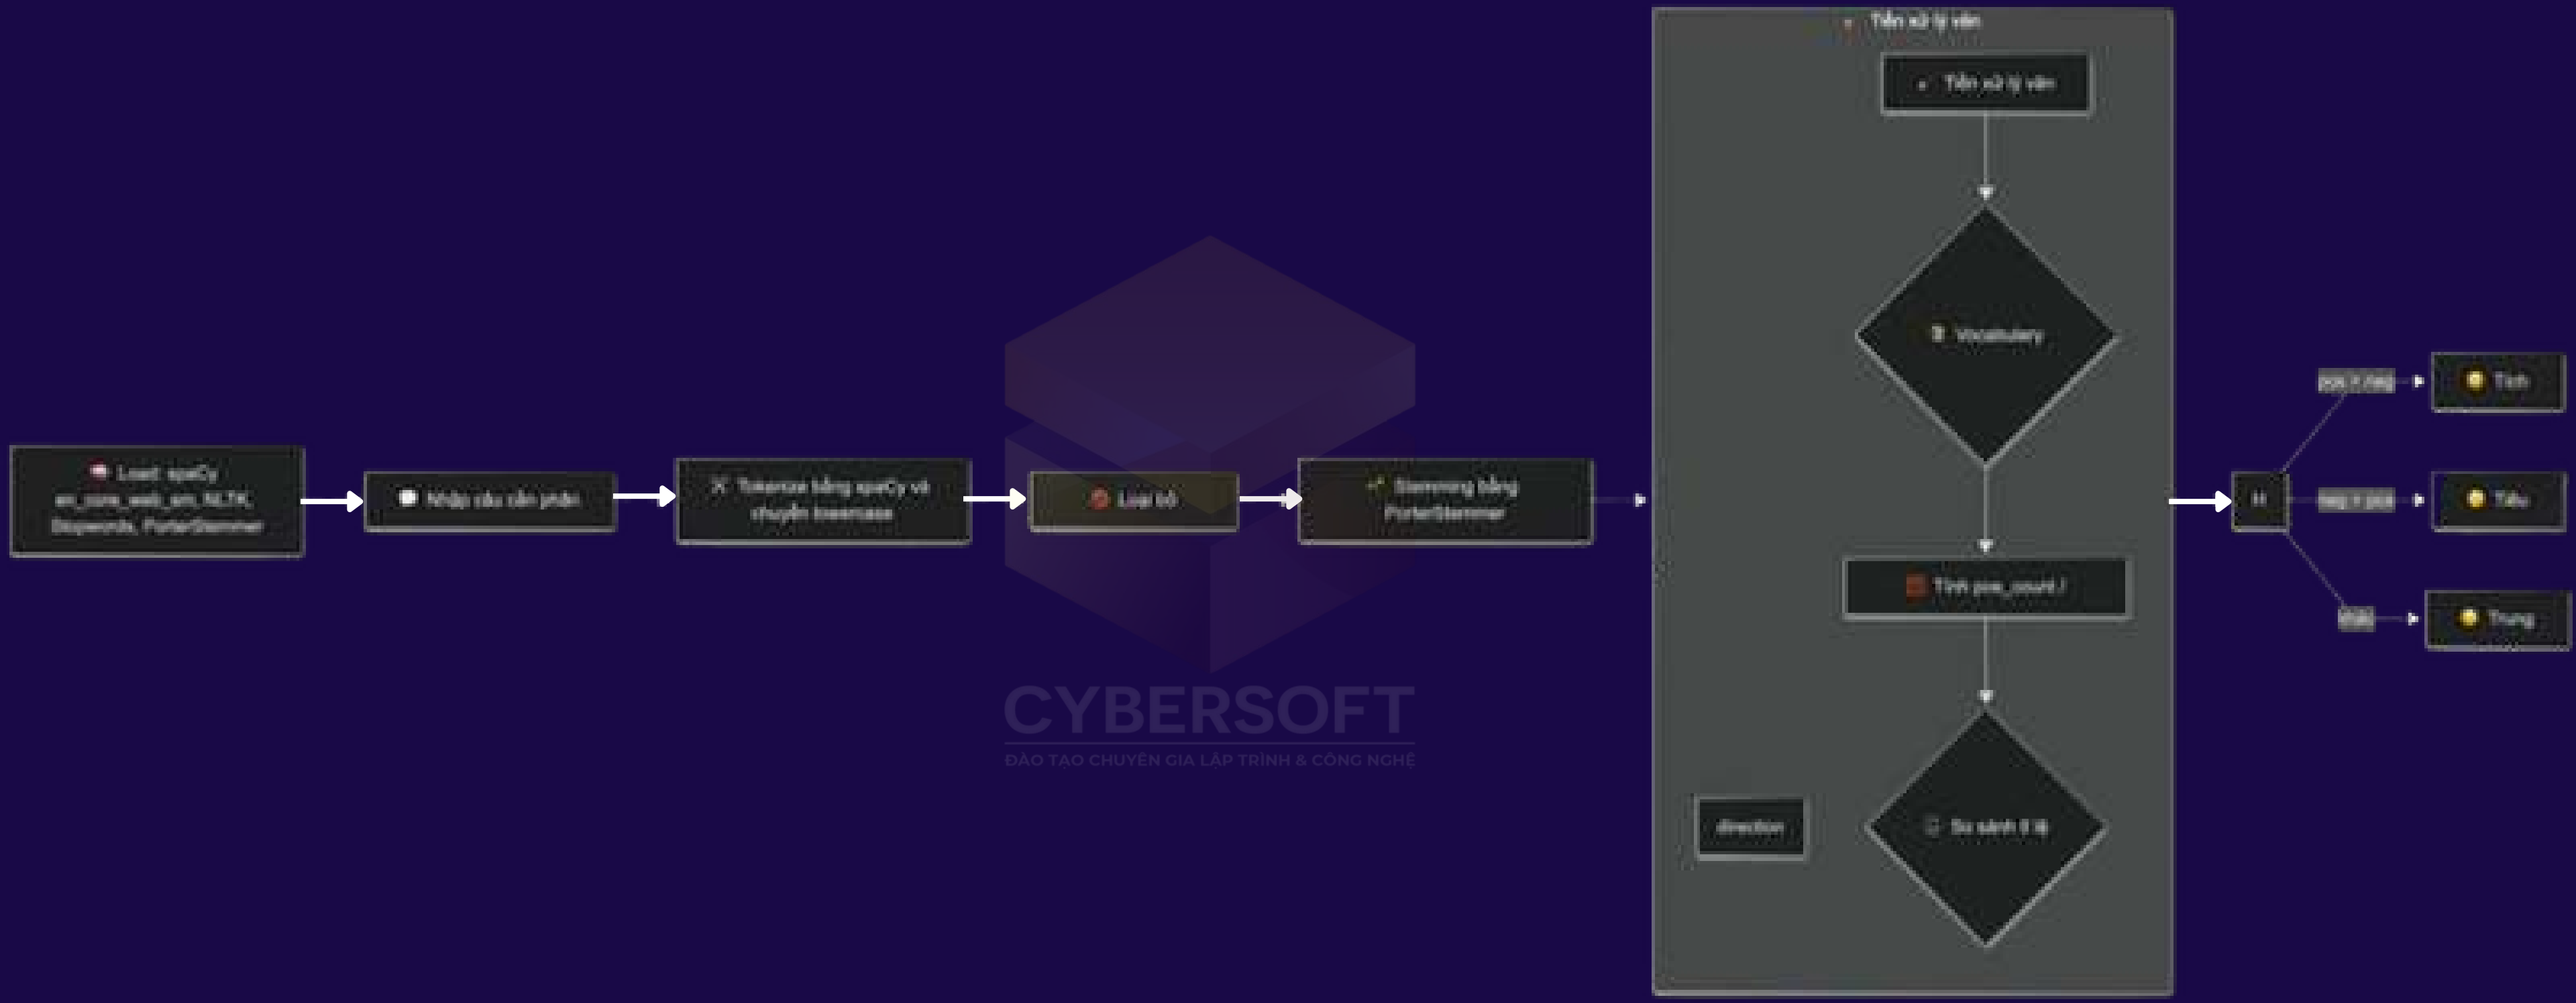


Bài tập thực hành

PIPELINE



Sentiment Basic



CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Các bước thực hiện

1. Cài đặt thư viện
2. Import thư viện
3. Tiền xử lý dữ liệu
4. Viết hàm dự đoán cảm xúc
5. Kiểm thử với dữ liệu mẫu
6. Full code

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH

Sentiment Basic

1. Cài đặt thư viện

```
!pip install pandas scikit-learn nltk kagglehub
```



Sentiment Basic

2. Import thư viện

```
import spacy
import nltk
from nltk.stem import PorterStemmer
from nltk.corpus import stopwords
nltk.download('punkt')
nltk.download('stopwords')

nlp = spacy.load("en_core_web_sm")  # Tải mô hình SpaCy cho Tokenization
stemmer = PorterStemmer()  # Stemmer cho Stemming
stop_words = set(stopwords.words('english'))  # Danh sách Stop-Words
```

Sentiment Basic

3. Tiền xử lý dữ liệu

```
def preprocess_text(sentence):
    # Bước 1: Tokenization bằng SpaCy
    doc = nlp(sentence.lower())  # Chuyển lowercase và xử lý bằng SpaCy
    tokens = [token.text for token in doc]

    # Giải thích Tokenization: Tokenization là quá trình chia văn bản thà

    # Bước 2: Loại bỏ Stop-Words
    filtered_tokens = [word for word in tokens if word not in stop_words]

    # Giải thích Stop-Words: Stop-Words là các từ phổ biến nhưng ít mang

    # Bước 3: Stemming để chuẩn hóa
    stemmed_tokens = [stemmer.stem(word) for word in filtered_tokens]

    # Giải thích Stemming: Stemming là quá trình cắt hậu tố để đưa từ về

    return stemmed_tokens
```

Sentiment Basic

4. Viết hàm dự đoán cảm xúc

```python
def analyze_sentiment(sentence):
    processed_tokens = preprocess_text(sentence)

    # Danh sách từ khóa tích cực/tiêu cực (Vocabulary)
    positive_vocab = ['love', 'great', 'excel', 'good', 'best', 'happi']  # Sa
    negative_vocab = ['hate', 'bad', 'worst', 'terribl', 'sad', 'bore']

    # Vocabulary-Matching: Kỹ thuật khớp từ với danh sách từ vựng (vocabulary)

    pos_count = sum(1 for word in processed_tokens if word in positive_vocab)
    neg_count = sum(1 for word in processed_tokens if word in negative_vocab)

    if pos_count > neg_count:
        return "Tích cực"
    elif neg_count > pos_count:
        return "Tiêu cực"
    else:
        return "Trung tính"
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Sentiment Basic

5. Kiểm thử với dữ liệu mẫu

```
review = "The movie is better than the previous one"
result = analyze_sentiment(review)
print(f"Kết quả: {result}")
```

```
Kết quả: Trung tính
```

CYBERSOFT
ĐÀO TẠO CHUYÊN GIA LẬP TRÌNH & CÔNG NGHỆ

Sentiment Basic

6. Full code

```python
# Tải mô hình SpaCy và Stop-Words
nlp = spacy.load("en_core_web_sm")
nltk.download('stopwords')
stop_words = set(stopwords.words('english'))

def preprocess_text(sentence):
    # Bước 1: Tokenization bằng SpaCy
    doc = nlp(sentence.lower())
    tokens = [token.text for token in doc]
    # Giải thích Tokenization: Chia văn bản thành token (từ, dấu câu) để xử lý tiếp t

    # Bước 2: Loại Stop-Words
    filtered_tokens = [token for token in tokens if token not in stop_words]
    # Giải thích Stop-Words: Loại từ thừa như "the", "is". Công dụng: Giảm nhiễu, tập

    # Bước 3: Lemmatization bằng SpaCy
    lemmas = [token.lemma_ for token in doc if token.text in filtered_tokens]
    # Giải thích Lemmatization: Chuyển từ về dạng gốc có nghĩa (như "better" → "good"

    return lemmas

def analyze_sentiment(sentence):
    processed_tokens = preprocess_text(sentence)

    # Danh sách từ vựng cảm xúc (sau Lemmatization)
    positive_vocab = ['love', 'great', 'excellent', 'good', 'well', 'best', 'happy']
    negative_vocab = ['hate', 'bad', 'worst', 'terrible', 'sad', 'boring']

    # Bước 4: Vocabulary-Matching
    # Giải thích Vocabulary-Matching: Khớp từ với danh sách từ vựng để phân loại cảm
    pos_count = sum(1 for word in processed_tokens if word in positive_vocab)
    neg_count = sum(1 for word in processed_tokens if word in negative_vocab)

    if pos_count > neg_count:
        return "Tích cực"
    elif neg_count > pos_count:
        return "Tiêu cực"
    else:
        return "Trung tính"


review = "The movie is better than the previous one"
result = analyze_sentiment(review)
print(f"Review: {review}")
print(f"Kết quả: {result}")  # Kết quả: Tích cực
```

```
['movie', 'well', 'previous', 'one']
Review: The movie is better than the previous one
Kết quả: Tích cực
[nltk_data] Downloading package stopwords to
[nltk_data]     /Users/vietannguyen/nltk_data...
[nltk_data]   Package stopwords is already up-to-date!
```